

# Trabalho 01

## Otimização sem Restrições

MEC 2403 - Otimização e Algoritmos para Engenharia Mecânica

**Felipe da Costa Pereira**  
felipecostapereira@gmail.com

Professor: Ivan Menezes



Departamento de Engenharia Mecânica  
PUC-RJ Pontifícia Universidade Católica do Rio de Janeiro  
outubro, 2022

# 1 Introdução

Otimização sem restrição (OSR) consiste em encontrar o mínimo de uma função  $f(\vec{x})$  onde não há restrição em relação ao domínio das variáveis  $\vec{x}$ . A fim de se encontrar o mínimo da função  $f(\vec{x})$  a partir de um ponto de partida ( $\vec{x}_0$ ), os métodos apresentados nesse trabalho consistem na repetição das etapas seguintes até que um critério de parada seja atingido:

1. Selecionar uma direção  $\vec{d}$  a partir do ponto  $\vec{x}_0$
2. Encontrar o mínimo da função  $f$  nessa direção, chegando a um novo ponto  $\vec{x}_1 = \vec{x}_0 + \alpha\vec{d}$ , onde  $\alpha$  é um número real (busca linear).
3. Tomar  $\vec{x}_1$  como o novo ponto de partida  $\vec{x}_0$
4. Repetir os passos de 1 a 3 até que uma condição de parada seja atingida: mínimo encontrado ( $|\vec{\nabla}f| = 0$ ), ou máximo número de iterações atingido.

A etapa descrita no item 2 consiste na minimização de uma função de uma única variável ( $\alpha$ ). Dessa forma o problema de minimização da função  $f(\vec{x})$  se torna um problema de sucessivas determinações de direções de busca e suas respectivas buscas lineares nessas direções.

## 2 Objetivos

Os principais objetivos deste trabalho são:

- Implementar numericamente os algoritmos de otimização: Univariate, Powell, Steepest Descent, Fletcher-Reeves, Newton-Raphson e BFGS.
- Avaliar a influência dos parâmetros dos algoritmos nas métricas de convergência e comparar essas últimas com os valores esperados da teoria.
- Aplicar os algoritmos implementados na solução do problema de OSR em três casos: uma função quadrática, uma não quadrática e uma terceira função que representa um problema de engenharia (minimização da energia de um sistema massa-mola visando encontrar seu ponto de equilíbrio estático)

As funções a serem minimizadas neste trabalho são:

Problema 01a):

$$f(x_1, x_2) = x_1^2 - 3x_1x_2 + 4x_2^2 + x_1 - x_2 \quad (1a)$$

a partir dos pontos iniciais  $x^0 = \{2, 2\}^t$  e  $x^0 = \{-1, -3\}^t$

Problema 01b):

$$f(x_1, x_2) = (1 + a - bx_1 - bx_2)^2 + (b + x_1 + ax_2 - bx_1x_2)^2 \quad (1b)$$

com  $a = 10$  e  $b = 1$  a partir dos pontos iniciais  $x^0 = \{10, 2\}^t$  e  $x^0 = \{-2, -3\}^t$

Problema 02:

$$\Pi(x_1, x_2) = 450(\sqrt{(30 + x_1)^2 + x_2^2} - 30)^2 + 300(\sqrt{(30 - x_1)^2 + x_2^2} - 30)^2 - 360x_2 \quad (2)$$

a partir do ponto inicial  $x^0 = \{0.01, -0.10\}^t$

## 3 Algoritmos de Busca Linear

Os algoritmos de minimização são executados em duas etapas conforme citado anteriormente: a primeira etapa consiste em determinar uma direção de busca  $\vec{d}$  e em seguida promove-se a minimização da função  $f$  nessa direção, o que significa encontrar o valor de  $\alpha = \alpha_k$  que minimiza a função  $f(x = x_0 + \alpha\vec{d})$  ao longo da direção  $\vec{d}$ . A partir do valor de  $\alpha_k$  encontra-se um novo ponto de partida  $f(x_{k+1} = x_k + \alpha_k\vec{d}_k)$ . Uma nova direção  $\vec{d}_{k+1}$  é então determinada e o processo se repete até que uma condição de parada seja atingida.

Neste trabalho, a busca linear é realizada em duas etapas: Passo constante e refinamento do cálculo de  $\alpha$  através do método da seção áurea.

Um maior detalhamento dos métodos de busca aqui apresentados, assim como outros comumente utilizados na solução de problemas de otimização pode ser encontrado em [Menezes et al., 2012].

### 3.1 Passo Constante

A primeira etapa da busca linear consiste numa busca inexata que visa encontrar um intervalo de valores do passo  $\alpha$ ,  $[\alpha_L, \alpha_H]$  que represente uma redução suficientemente grande da função  $f$ . Essa implementação numérica incrementa o passo de um valor  $d\alpha$  até que a função pare de diminuir.

### 3.2 Bisseção e Seção Áurea

Após a etapa do passo constante, os métodos da Bisseção ou Seção Áurea são aplicados para encontrar o valor de  $\alpha$ , entre os valores determinados no intervalo da etapa 1. Em ambos os casos, o intervalo de ocorrência do valor mínimo de  $f$  é sucessivamente reduzido até que seja muito pequeno e considera-se, dado esse critério numérico, solucionado o problema da minimização de  $f$  nessa direção, encontrando o passo  $\alpha_k$  correspondente a esse mínimo.

O método da bisseção divide sucessivamente o intervalo descartando a parte superior ou inferior do mesmo avaliando o valor da função  $f$  na vizinhança esquerda e direita de um  $\alpha_M$  médio do intervalo. Já o método da seção áurea utiliza a razão áurea para descarte dos intervalos onde  $f$  aumenta. Este último método realiza mais passos, porém possui a vantagem de avaliar menos vezes a função  $f$  uma vez que os valores avaliados no passo anterior podem ser reutilizados no passo seguinte do algoritmo, o que pode ser interessante em problemas onde a avaliação da função  $f$  é computacionalmente cara.

## 4 Algoritmos de Direção

Conforme descrito anteriormente, os métodos de direção determinam direções de busca do mínimo de  $f$  a partir de um ponto  $\vec{x}_k$ . A partir da busca linear encontra-se o valor do passo nessa direção que minimiza  $f$ ,  $(\alpha_k)$ , os algoritmos de direção calculam, então, a próxima direção onde se deve minimizar  $f$  e a partir do novo ponto  $\vec{x}_{k+1} = \vec{x}_k + \alpha_k \vec{d}$ .

Os algoritmos de determinação das direções de busca utilizados nesse trabalho são brevemente descritos a seguir.

Um maior detalhamento dos algoritmos de direção aqui apresentados, assim como outros comumente utilizados na solução de problemas de otimização pode ser encontrado em [Menezes et al., 2012].

### 4.1 Univariante

O método univariante é o mais simples, onde as direções de busca são as direções canônicas,  $\vec{d}_k = \vec{e}_k$ . Esse procedimento é equivalente a modificar uma variável de cada vez no processo iterativo, ou seja, apenas a variável na posição  $k$  do vetor de variáveis  $\vec{x}$  é modificada na iteração  $k$  ([Menezes et al., 2012]).

### 4.2 Powell

O método de Powell utiliza em seu algoritmo direções denominadas "movimento padrão". O método de Powell gera direções Q-conjugadas, o que representa uma aceleração em relação ao método univariante. Um maior detalhamento sobre o método de Powell e a demonstração de que o método de Powell converge para o mínimo de uma função quadrática de  $n$  variáveis em um número finito de passos dado por  $n + 1$  está descrito em ([Menezes et al., 2012]).

### 4.3 Steepest Descent

O método Steepest Descent é um método onde as direções são dadas pela direção oposta ao gradiente da função  $f$ . Ou seja,  $\vec{d}_k = -\vec{\nabla} f(\vec{x}_k)$ .

### 4.4 Fletcher-Reeves

Este método consiste em uma adaptação do método dos Gradientes Conjugados que o torna capaz de ser usado para minimização de uma função qualquer. Para isso, duas modificações precisam ser realizadas, a avaliação da matriz Q (ou Hessiana para função não quadrática) é substituída por uma busca linear e o parâmetro  $\beta$  modificado ([Menezes et al., 2012]).

## 4.5 Newton-Raphson

O princípio deste método é minimizar uma função  $f$  através de uma aproximação local por uma função quadrática. A direção de minimização de  $f$  é obtida a partir da derivada da expansão de  $f$  numa série de Taylor de ordem 2 em relação a  $\vec{d}_k$ , de onde se obtém:  $\vec{d}_k = -H^{-1}\vec{\nabla}f(\vec{x}_k)$ , onde  $H$  é a matriz Hessiana da função  $f$  ([Menezes et al., 2012]).

## 4.6 BFGS

O método Broyden-Fletcher-Goldfarb-Shanno (BFGS) é um método para resolver um problema de otimização não linear sem restrições. trata-se de uma solução frequentemente usada quando se deseja um algoritmo com direções de descida.

A ideia principal deste método é evitar a construção explícita da matriz Hessiana e, em vez disso, construir uma aproximação da inversa da segunda derivada da função a ser minimizada, analisando os diferentes gradientes sucessivos. Esta aproximação das derivadas da função leva a um método quase-Newton (uma variante do método de Newton) para encontrar a direção de busca. A matriz Hessiana não precisa ser recalculada a cada iteração do algoritmo. No entanto, o método assume que a função pode ser aproximada localmente por uma expansão quadrática limitada em torno do ótimo ([Broyden et al., ]).

## 5 Metodologia

Para atingir os objetivos do trabalho, foram programados scripts em linguagem Matlab, organizados conforme esquematizado na figura 1.

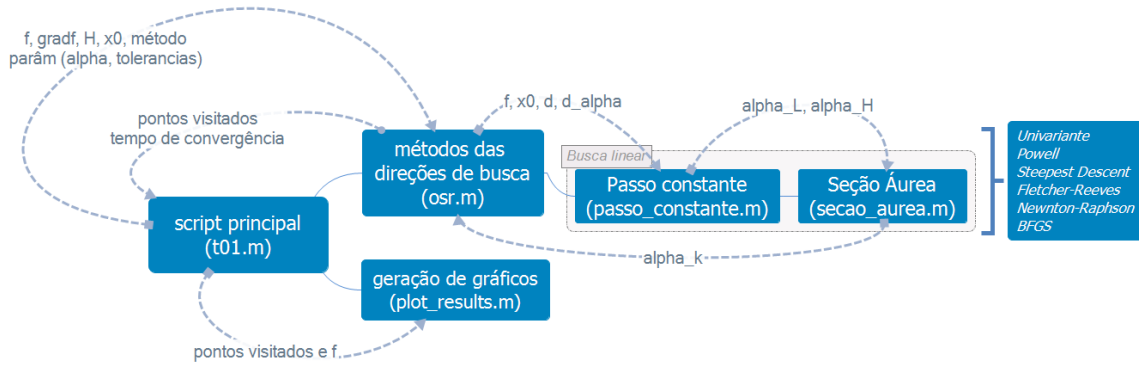


Figura 1: Fluxo dos scripts

Um script principal *t01.m* escolhe os parâmetros do algoritmo:  $a = d\alpha$  (passo da busca linear), máximo número de iterações (*iter\_max*) e tolerâncias para avaliar a convergência da função para um mínimo ou da seção áurea: *TOL* e *TOL2*, respectivamente. Além disso esse script cria as funções, seus gradientes, matriz Hessiana e pontos iniciais, a serem passados como parâmetros para o script que implementa os algoritmos, conforme ilustrado no anexo 1.

Em seguida, o script *t01.m* chama o script *osr.m* (anexo 2) para cada método e plota as curvas de nível da função  $f$  e todos os pontos visitados durante a busca do algoritmo através do script *plot\_result.m*.

O script *osr.m* implementa de fato os algoritmos a partir dos parâmetros recebidos, retornando todos os valores de  $\vec{x}$  visitados e o tempo de execução, conforme o anexo 3.

Outros dois scripts invocados na solução dos problemas propostos são *passo\_constante.m* e *secao\_aurea.m*, que realizam a etapa de busca linear para cada direção de busca. Esses códigos encontram-se nos anexos 4 e 5, respectivamente. O script *plot\_result.m* é listado no anexo 6.

## 6 Resultados

Visando a convergência de todos os métodos, foram testados alguns valores dos parâmetros dos algoritmos. A melhor combinação dos parâmetros, para as funções dos problemas 1 e 2 em termos de convergência dos algoritmos está listada na tabela 1.

**Tabela 1:** Melhores parâmetros para convergência dos algoritmos

	$d\alpha$	TOL(gradiente)	TOL2(busca linear)	max_iter
Problema 01	0.002	1e-4	1e-7	100
Problema 02	0.005	5e-4	1e-7	100

As tabelas 2, 3 apresentam os principais resultados dos algoritmos implementados para as funções dos itens 1a e 1b. Além dos pontos de mínimo encontrado, as tabelas apresentam também o número de passos para a convergência e o tempo de execução.

**Tabela 2:** Resultados para a função 1a

método	$x^0$	$x^{min}$	passos	$\Delta t(\text{ms})$
Univariante	$\{2, 2\}^t$	$\{-0.7142, -0.1428\}^t$	34	4.8
Univariante	$\{-1, -3\}^t$	$\{-0.7144, -0.1429\}^t$	36	6.9
Powell	$\{2, 2\}^t$	$\{-0.7143, -0.1429\}^t$	6	24.8
Powell	$\{-1, -3\}^t$	$\{-0.7143, -0.1429\}^t$	12	7.2
Steepest Descent	$\{2, 2\}^t$	$\{-0.7142, -0.1428\}^t$	25	6.5
Steepest Descent	$\{-1, -3\}^t$	$\{-0.7143, -0.1429\}^t$	7	3.0
Fletcher-Reeves	$\{2, 2\}^t$	$\{-0.7143, -0.1429\}^t$	2	2.5
Fletcher-Reeves	$\{-1, -3\}^t$	$\{-0.7143, -0.1429\}^t$	2	1.7
Newton-Raphson	$\{2, 2\}^t$	$\{-0.7143, -0.1429\}^t$	1	2.5
Newton-Raphson	$\{-1, -3\}^t$	$\{-0.7143, -0.1429\}^t$	1	1.1
BFGS	$\{2, 2\}^t$	$\{-0.7143, -0.1429\}^t$	2	2.2
BFGS	$\{-1, -3\}^t$	$\{-0.7143, -0.1429\}^t$	2	1.5


No caso da função do item 1a, o método de Powell levou mais passos do que o esperado em teoria para uma função quadrática, já que nesse caso é esperado que o mesmo atinja a convergência em até 9 passos.

**Tabela 3:** Resultados para a função 1b

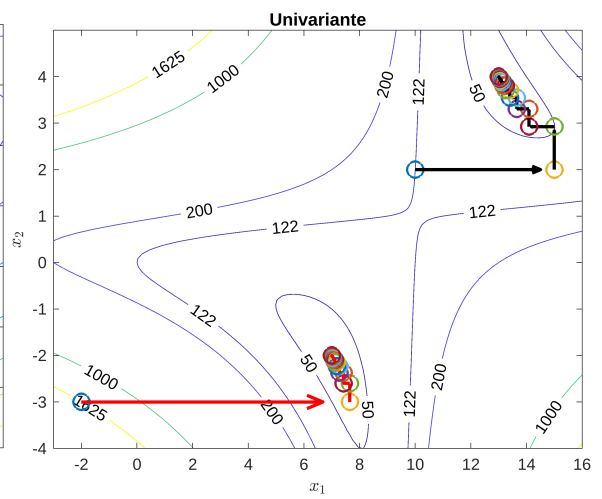
método	$x^0$	$x^{min}$	passos	$\Delta t(\text{ms})$
Univariante	$\{10, 2\}^t$	$\{13.0000, 4.0000\}^t$	45	9.9
Univariante	$\{-2, -3\}^t$	$\{7, -2\}^t$	45	10.8
Powell	$\{10, 2\}^t$	$\{13.0000, 4.0000\}^t$	24	11.6
Powell	$\{-2, -3\}^t$	$\{7, -2\}^t$	18	8.0
Steepest Descent	$\{10, 2\}^t$	$\{13.0000, 4.0000\}^t$	46	2.3
Steepest Descent	$\{-2, -3\}^t$	$\{7, -2\}^t$	59	2.6
Fletcher-Reeves	$\{10, 2\}^t$	$\{13.0000, 4.0000\}^t$	41	1.6
Fletcher-Reeves	$\{-2, -3\}^t$	$\{7, -2\}^t$	16	0.9
Newton-Raphson(*)	$\{10, 2\}^t$	$\{10, 1\}^t$	1	0.9
Newton-Raphson	$\{-2, -3\}^t$	$\{12.9999, 4.0001\}^t$	6	4.1
BFGS	$\{10, 2\}^t$	$\{13.0000, 4.0000\}^t$	7	4.1
BFGS	$\{-2, -3\}^t$	$\{7, -2\}^t$	6	5.7

No caso da função do item 1b nota-se que o método de Newton-Raphson não convergiu para o primeiro ponto (\*). Na verdade o algoritmo parou no critério de norma do gradiente no primeiro passo, o que leva a uma convergência para um valor equivocado. De fato a busca linear nesse caso retornou um valor tal que, ao final do primeiro passo o algoritmo caiu num ponto o gradiente de  $f$  é muito pequeno. Tal problema pode ser visualizado também graficamente na figura 6b.

As figuras de 2 a 7 a seguir ilustram as curvas de nível de  $f$  para os casos das funções dos itens 1a e 1b, bem como a trajetória dos pontos  $\vec{x}_k$  associados ao algoritmo de minimização.

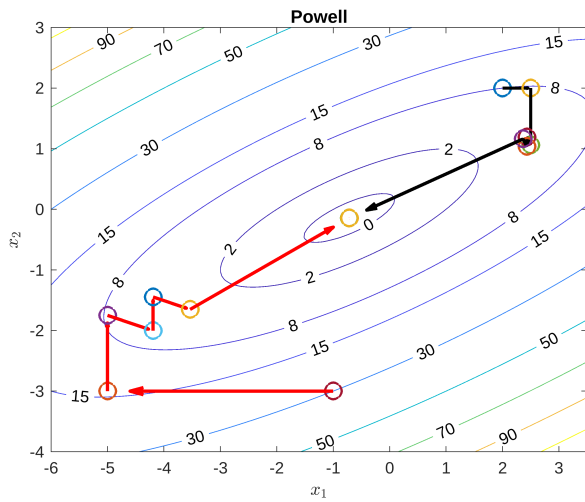


(a) Curvas de nível de  $f_{1a}$  e pontos  $x_k$




(b) Curvas de nível de  $f_{1b}$  e pontos  $x_k$

**Figura 2:** Resultados do método univariante, para as duas funções e pontos iniciais




(a) Curvas de nível de  $f_{1a}$  e pontos  $x_k$

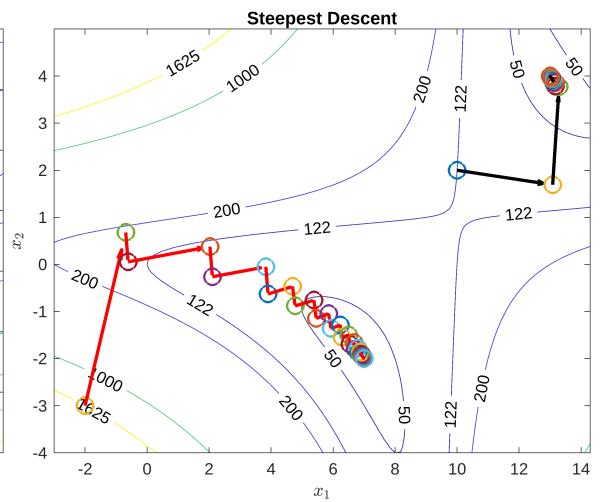


(b) Curvas de nível de  $f_{1b}$  e pontos  $x_k$

**Figura 3:** Resultados do método de Powell, para as duas funções e pontos iniciais

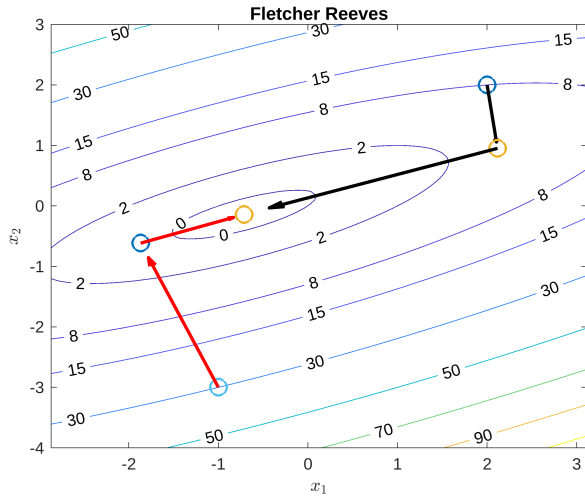


(a) Curvas de nível de  $f_{1a}$  e pontos  $x_k$

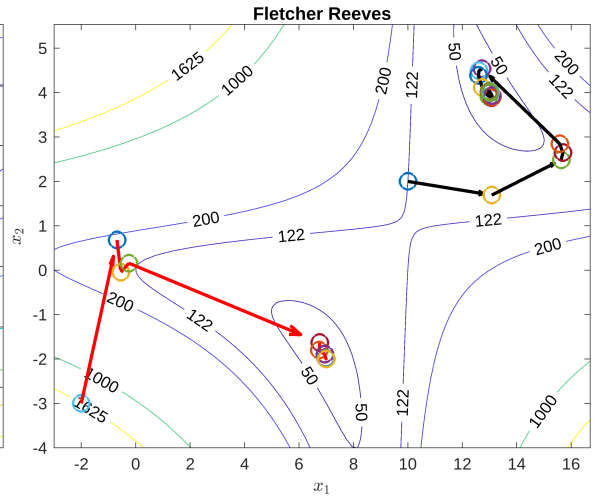


(b) Curvas de nível de  $f_{1b}$  e pontos  $x_k$

**Figura 4:** Resultados do método Steepest Descent, para as duas funções e pontos iniciais




(a) Curvas de nível de  $f_{1a}$  e pontos  $x_k$




(b) Curvas de nível de  $f_{1b}$  e pontos  $x_k$

**Figura 5:** Resultados do método Fletcher-Reeves, para as duas funções e pontos iniciais




(a) Curvas de nível de  $f_{1a}$  e pontos  $x_k$




(b) Curvas de nível de  $f_{1b}$  e pontos  $x_k$

**Figura 6:** Resultados do método Newton-Raphson, para as duas funções e pontos iniciais



(a) Curvas de nível de  $f_{1a}$  e pontos  $x_k$



(b) Curvas de nível de  $f_{1b}$  e pontos  $x_k$

**Figura 7:** Resultados do método BFGS, para as duas funções e pontos iniciais

A tabela 4 apresenta os principais resultados dos algoritmos implementados para a função do item 2. Além


dos pontos de mínimo encontrados, as tabelas apresentam também o número de passos para a convergência e o tempo de execução.

**Tabela 4:** Resultados para a função 2

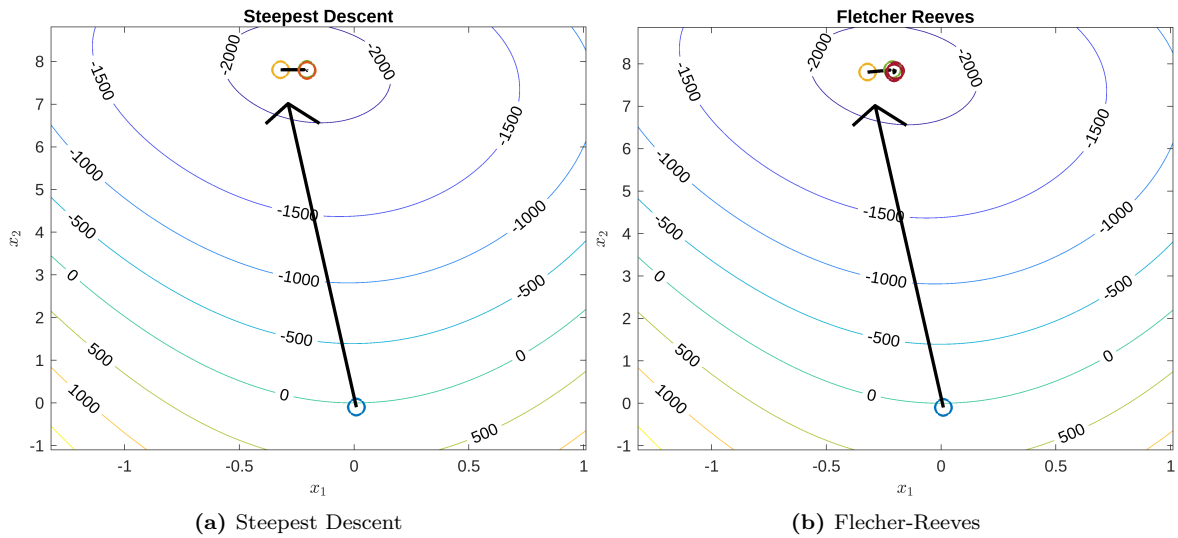
método	$x^0$	$x^{min}$	passos	$\Delta t(\text{ms})$
Univariante	$\{0.01, -0.10\}^t$	$\{-0.205, 7.789\}^t$	11	2.1
Powell	$\{0.01, -0.10\}^t$	$\{-0.205, 7.789\}^t$	12	6340.8(**)
Steepest Descent	$\{0.01, -0.10\}^t$	$\{-0.205, 7.789\}^t$	6	0.3
Fletcher-Reeves	$\{0.01, -0.10\}^t$	$\{-0.205, 7.789\}^t$	10	0.4
Newton-Raphson	$\{0.01, -0.10\}^t$	$\{-0.205, 7.789\}^t$	3	4.4
BFGS	$\{0.01, -0.10\}^t$	$\{-0.205, 7.789\}^t$	3	0.3

No caso da função do item 2 nota-se que o elevado tempo de execução do método de Powell (\*\*) em relação aos demais.

A figuras 8, 9 e 10 a seguir ilustram, para os seis métodos, as curvas de nível de  $f$  para os casos da função do item 2, bem como a trajetória dos pontos  $x_k$  associadas ao algoritmo de minimização.



**Figura 8:** Curvas de nível de  $f_2$  e pontos  $x_k$ , métodos de ordem zero



**Figura 9:** Curvas de nível de  $f_2$  e pontos  $x_k$ , métodos de ordem um






Figura 10: Curvas de nível de  $f_2$  e pontos  $x_k$ , métodos de Newton-Raphson e BFGS

## 7 Conclusões

## 8 Anexos

A seguir estão ilustrados alguns dos códigos ou trechos de códigos decritos na metodologia.

### Anexo 1: script t01.m setando parâmetros e criando as funções

```
% dados do item 01a, f, grad f, hess f e x0
fa = @(x) x(1)^2-3*x(1)*x(2)+4*x(2)^2+x(1)-x(2);
gfa = @(x) [2*x(1)-3*x(2)+1; -3*x(1)+8*x(2)-1];
Ha = @(x) [2 -3; -3 8];
x01 = [2;2];
x02 = [-1;-3];
% parametros dos algoritmos
iter_max = 100;
a = 0.002; % passo
TOL = 1e-4; % parada do gradiente
TOL2 = 1e-7; % busca linear
methods = ["Univariante", "Powell", "Steepest Descent", "Fletcher Reeves", "Newton-Raphson", "BFGS"];
```

### Anexo 2: script t01.m chamando o script osr.m para a função do item 1a para cada um dos 6 métodos estudados

```
fprintf('\n*****ITEM_01A*****\n');
for method = 1:6
    fprintf('---%s---\n', methods(method));

    fprintf('x0=[%2d,%2d];\n', x01(1), x01(2));
    [x_1,t] = osr(fa, gfa, Ha, x01, method, iter_max, a, TOL, TOL2);
    fprintf('(%fms), xmin=[%0.4f,%0.4f], f=%0.4f\n', t*1000, x_1(1,end), x_1(2,end), fa(x_1(:,end)));

    fprintf('x0=[%2d,%2d];\n', x02(1), x02(2));
    [x_2,t] = osr(fa, gfa, Ha, x02, method, iter_max, a, TOL, TOL2);
    fprintf('(%fms), xmin=[%0.4f,%0.4f], f=%0.4f\n', t*1000, x_2(1,end), x_2(2,end), fa(x_2(:,end)));

    plot_result(min([x_1(1,:), x_2(1,:)]-dx, max([x_1(1,:), x_2(1,:)]+dx), min([x_1(2,:), x_2(2,:)]-dx, max([x_1(2,:), x_2(2,:)]+dx), x_1,
        x_2, methods(method), 1)
    exportgraphics(gcf, strcat('./figures/img01A_m0', num2str(method), '.png'), 'Resolution', 500)
end
```

### Anexo 3: script osr.m implementando o método de Powell

```
function [x_,time_elap] = osr (f, gf, H, x0, method, iter_max, a, TOL, TOL2)
% 1. Univariate
% 2. Powell
% 3. Steepest Descent
% 4. Fletcher-Reeves
% 5. Newton-Raphson
% 6. BFGS

k=0;
conv=0; %flag convergencia
tstart = tic;
switch method
case 2
% 2. Powell
x_ = x0;
x = x0;
while k < iter_max
j = 1;
n = 2;
y = [[1;0],[0;1]];
while j <= n
[alpha_L, alpha_H] = passo_constante(f, x, y(:,1), a);
alpha_k = secas_aurea(f, x, y(:,1), TOL2, alpha_L, alpha_H);
k=k+1;
x = x + alpha_k*y(:,1);
x_ = [x_,x];
[alpha_L, alpha_H] = passo_constante(f, x, y(:,2), a);
alpha_k = secas_aurea(f, x, y(:,2), TOL2, alpha_L, alpha_H);
k=k+1;
x = x + alpha_k*y(:,2);
x_ = [x_,x];
d = x-x0;
[alpha_L, alpha_H] = passo_constante(f, x, d, a);
alpha_k = secas_aurea(f, x, d, TOL2, alpha_L, alpha_H);
k=k+1;
x0 = x + alpha_k*d;
x=x0;
x_ = [x_,x];

y(:,1) = y(:,2);
y(:,2) = d;

j = j+1;
end
if norm(gf(x)) < TOL
fprintf('%d steps!', k);
conv=1;
break;
end
end
if conv == 0
fprintf('Nao convergiu apos %d steps', k);
end
```

### Anexo 4: script passo\_constante.m

```
function [alpha_L, alpha_H] = passo_constante(f, x0, d, a)
alpha = 0;
f_min = Inf;
f_val = f(x0);
alphas = [];
f1 = f(x0 - a*d);
f2 = f(x0 + a*d);
if f1 < f2
a=-a; % desce a esq (d-)
end
while f_val <= f_min
x = x0 + alpha * d;
f_val = f(x);
if f_val < f_min
f_min = f_val;
end
alphas = [alphas; alpha];
alpha = alpha + a;
end
alpha_L = alphas(end-1);
alpha_H = alphas(end);
if a < 0
alpha_H = alphas(end-1);
alpha_L = alphas(end);
end
end
```

## Anexo 5: script secao\_aurea.m

```
function alpha_k = secao_aurea (f, x0, d, TOL, alpha_L, alpha_H)
    ra = (sqrt(5)-1)/2;
    b = norm(alpha_L-alpha_H);
    alpha_E = alpha_L + (1-ra)*b;
    alpha_D = alpha_L + ra*b;
    f1 = f(x0 + alpha_E * d);
    f2 = f(x0 + alpha_D * d);
    while b > TOL
        if f1 > f2
            alpha_L = alpha_E;
            alpha_E = alpha_D;
            b = norm(alpha_L-alpha_H);
            alpha_D = alpha_L + ra*b;
            % avaliar menos vezes a funcao f
            f1 = f2;
            f2 = f(x0 + alpha_D * d);
        else
            alpha_H = alpha_D;
            alpha_D = alpha_E;
            b = norm(alpha_L-alpha_H);
            alpha_E = alpha_L + (1-ra)*b;
            % avaliar menos vezes a funcao f
            f2 = f1;
            f1 = f(x0 + alpha_E * d);
        end
    end
    alpha_k = (alpha_L+alpha_H)/2;
end
```

## Anexo 6: script plot\_result.m

```
function [] = plot_result(xmin, xmax, ymin, ymax, x_, x2_, graph_title, func)
    n = length(x_);
    n2 = length(x2_);
    figure
    x1 = linspace(xmin, xmax, 100);
    x2 = linspace(ymin, ymax, 100);
    [x1,x2] = meshgrid(x1,x2);
    if func == 1
        fplot = x1.^2 - 3*x1.*x2 + 4*x2.^2 + x1 - x2;
        contour(x1, x2, fplot, [0 2 8 15 30:20:120], 'ShowText','on');
    elseif func == 2
        fplot = (11-x1-x2).^2 + (1+x1+10*x2-x1.*x2).^2;
        contour(x1, x2, fplot, [50 122 200 1000 1625 5000 10000], 'ShowText','on')
    else
        fplot = 450*(sqrt((30+x1).^2+x2.^2)-30).^2+300*(sqrt((30-x1).^2+x2.^2)-30).^2-360*x2;
        contour(x1, x2, fplot, 'ShowText','on')
    end
    title(graph_title)
    xlabel('$x_1$', 'Interpreter', 'latex')
    ylabel('$x_2$', 'Interpreter', 'latex')
    hold on
    for k = 1:n
        plot(x_(1,k), x_(2,k),'o', 'LineWidth', 2, 'MarkerSize', 10)
        if k<n
            desenha_flecha(x_(:,k)', x_(:,k+1)', 'k');
        end
    end
    if ~ isempty(x2_)
        for k = 1:n2
            plot(x2_(1,k), x2_(2,k),'o', 'LineWidth', 2, 'MarkerSize', 10)
            if k<n2
                desenha_flecha(x2_(:,k)', x2_(:,k+1)', 'r');
            end
        end
    end
end
```

## Referências

- [Broyden et al.,] Broyden, C. G., Fletcher, R., Goldfarb, D., and Shanno, D. F. Método de broyden-fletcher-goldfarb-shanno. [https://pt.frwiki.wiki/wiki/M%C3%A9thode\\_de\\_Broyden-Fletcher-Goldfarb-Shanno#R%C3%A9f%C3%A9rences](https://pt.frwiki.wiki/wiki/M%C3%A9thode_de_Broyden-Fletcher-Goldfarb-Shanno#R%C3%A9f%C3%A9rences). Acessado em: 10/10/2022.
- [Menezes et al., 2012] Menezes, I. F. M., Luiz, E. V., and Pereira, A. (2012). Programação matemática, teoria, algoritmos e aplicações.